

HW 1

FLOPs : 1 MAC = 2 FLOPs

Input: $B \times 3 \times S \times S$

FP32 (4 Summa / su.)

Conv : padding = k/2 bias = false

$$\begin{aligned} 3 \times S \times S &\xrightarrow{\text{Conv } 7 \times 7, s_2} 32 \times \frac{S}{2} \times \frac{S}{2} \\ &\xrightarrow{\text{Max Pool, } s_2} 32 \times \frac{S}{4} \times \frac{S}{4} \\ &\xrightarrow{\text{Conv } 5 \times 5} 64 \times \frac{S}{4} \times \frac{S}{4} \\ &\xrightarrow{\text{Conv } 3 \times 3, s_2} 128 \times \frac{S}{8} \times \frac{S}{8} \\ &\xrightarrow{\text{Conv } 1 \times 1} 256 \times \frac{S}{8} \times \frac{S}{8} \\ &\xrightarrow{\text{Conv } 3 \times 3, s_2} 256 \times \frac{S}{16} \times \frac{S}{16} \\ &\xrightarrow{\text{Conv } 1 \times 1} 512 \times \frac{S}{16} \times \frac{S}{16} \end{aligned}$$

$$\xrightarrow{\text{GAP}} 512 \longrightarrow 256 \longrightarrow 100$$

FLOPs

$$F_{\text{conv}} = 2 \cdot B \cdot C_{\text{in}} \cdot C_{\text{out}} \cdot K^2 \cdot H_{\text{out}} \cdot W_{\text{out}}$$

$\uparrow$
T.K. 1 MAC = 2 FLOPs

$$F_{\text{conv}1} = 2 \cdot 3 \cdot 32 \cdot 7^2 \cdot \left(\frac{S}{2}\right)^2 = 2352 S^2$$

$$F_{\text{conv}2} = 2 \cdot 32 \cdot 64 \cdot 5^2 \cdot \left(\frac{S}{4}\right)^2 = 6400 \cdot S^2$$

$$F_{\text{conv}3} = 2 \cdot 64 \cdot 128 \cdot 3^2 \cdot \left(\frac{S}{8}\right)^2 = 2304 \cdot S^2$$

$$F_{\text{conv}4} = 2 \cdot 128 \cdot 256 \cdot \left(\frac{S}{8}\right)^2 = 1024 \cdot S^2$$

$$F_{\text{conv}5} = 2 \cdot 256 \cdot 256 \cdot 3^2 \cdot \left(\frac{S}{16}\right)^2 = 4608 S^2$$

$$F_{\text{conv}6} = 2 \cdot 256 \cdot 512 \cdot \left(\frac{S}{16}\right)^2 = 1024 \cdot S^2$$

$$\text{sum} = 17712 S^2$$

+ Дополнительно учитываем
1 сравнение на каждый элемент
ReLU и $K^2 - 1$ сравнений на
каждый выходной элемент MaxPool
продолжение по ReLU ниже

$$F_{\text{ReLU1}} = 8S^2$$

$$F_{\text{MAXPOOL}} = 16S^2$$

$$F_{\text{ReLU2}} = 4S^2$$

$$F_{\text{ReLU3}} = 2S^2$$

$$F_{\text{ReLU4}} = 4S^2$$

$$F_{\text{ReLU5}} = S^2$$

$$F_{\text{ReLU6}} = 2S^2$$

$$\text{sum} = 21S^2$$

$$F_{\text{GAP}} = 2S^2 + 512$$

$$F_{\text{FC}} = 2 \cdot 512 \cdot 256 + 256 = 262400$$

→ fully connected layer

$$F_{\text{ReLU-FC}} = 256$$

$$F_{\text{FC2}} = 2 \cdot 256 \cdot 100 + 100 = 51300$$

$$U_{5020}, \text{FLOPs}(S, B) = B(39S^2 + 17712S^2 + 263168 + 51300) = B \cdot (17751S^2 + 314468)$$

$$\underline{\text{FLOPs}(S, B) = B \cdot (17751 \cdot S^2 + 314468)}$$

Memory

Аналитическая модель:

память на параметры + входные данные + длина памяти, выделенной на все активации. В такой модели активации не освобождаются.

Inplace ReLU не создает доп. активаций

$$P_{\text{conv}} = C_{\text{in}} \cdot C_{\text{out}} \cdot K^2$$

$$P_{\text{Linear}} = (C_{\text{in}} + 1) \cdot C_{\text{out}}$$

$$P_1 = 3 \cdot 32 \cdot 7^2 = 4704$$

$$P_2 = 32 \cdot 64 \cdot 5^2 = 51200$$

$$P_3 = 64 \cdot 128 \cdot 3^2 = 73728$$

$$P_4 = 128 \cdot 256 = 32768$$

$$P_5 = 256 \cdot 256 \cdot 3^2 = 589824$$

$$P_6 = 256 \cdot 512 = 131072$$

$$P_{\text{FC1}} = (512 + 1) \cdot 256 =$$

$$= 131328$$

$$P_{\text{FC2}} = (256 + 1) \cdot 100 =$$

$$= 25700$$

$$\text{Sum: } P = 1\,040\,324$$

Активации на одно изображение:

$$3S^2$$

input, плюс

$$32 \cdot \left(\frac{S}{2}\right)^2 = 8S^2$$

$$32 \cdot \left(\frac{S}{4}\right)^2 = 2S^2$$

$$64 \cdot \left(\frac{S}{4}\right)^2 = 4S^2$$

$$128 \cdot \left(\frac{S}{8}\right)^2 = 2S^2$$

$$256 \cdot \left(\frac{S}{8}\right)^2 = 4S^2$$

$$256 \cdot \left(\frac{S}{16}\right)^2 = S^2$$

$$512 \cdot \left(\frac{S}{16}\right)^2 = 2S^2$$

$$\text{и } 512 + 256 + 100$$

$$\text{Sum } 26S^2 + 868$$

$$\text{FP32} = 4 \text{ байта}$$

$$\text{Memory}(S, B) = 4 \cdot [1040324 + B \cdot (26S^2 + 868)]_{\text{байт}}$$

Bytes moved

Идеализованная модель обмена данными:
каждый шол один раз считывает
входные данные; эффект кша
не учитывается

Для обычного шол: чтение входа +
+ чтение параметров + запись выхода, то есть

$$M_c = 4 (B \cdot N_{in,c} + P_c + B \cdot N_{out,c})$$

↑
т.к. FP32

← параметры шол
↑
число элементов на одно
изображение input/output тензора

Для in place ReLU: у ReLU нет
параметров + in place $\Rightarrow$ пишем в том же
тензоре

$$M_{ReLU} = 4 \cdot (2 \cdot B \cdot N)$$

↑
FP32

на одно изображение N элементов, и нужно
прочитать и записать обратно $\Rightarrow \times 2$

Расчет

учитываем на B, где нужно

Слой	N_{in}	N_{out}	P_c	$\frac{M_c}{4}$
Conv ₁	$3 S^L$	$8 S^L$	4704	$11 B S^2 + 4704$
ReLU ₁	$8 S^2$	tot. не тензор	0	$16 B S^2$
Max Pool	$8 S^2$	$2 S^2$	0	$10 B S^2$
Conv ₂	$2 S^2$	$4 S^2$	51200	$6 B S^2 + 51200$
ReLU ₂	$4 S^2$	tot. не тензор	0	$8 B S^2$
Conv ₃	$4 S^2$	$2 S^2$	73728	$6 B S^2 + 73728$
ReLU ₃	$2 S^2$	tot. не тензор	0	$4 B S^2$
Conv ₄	$2 S^2$	$4 S^2$	32768	$6 B S^2 + 32768$
ReLU ₄	$4 S^2$	tot. не тензор	0	$8 B S^2$
Conv ₅	$4 S^2$	S^2	589824	$5 B S^2 + 589824$
ReLU ₅	S^2	tot. не тензор	0	$2 B S^2$
Conv ₆	S^2	$2 S^2$	131072	$3 B S^2 + 131072$
ReLU ₆	$2 S^2$	tot. не тензор	0	$4 B S^2$
Avg Pool	$2 S^2$	512	0	$2 B S^2 + 512 B$
FC ₁	512	256	131328	$768 B + 131328$
ReLU FC	256	tot. не тензор	0	$512 B$
FC ₂	256	100	25700	$356 B + 25700$

Суммирование: $91BS^2$

$\text{Sum } P_L = 1040324$

$2148B$

$$\text{Bytes Moved } (S, B) = 4 \cdot [91BS^2 + 2148B + 1040324]$$

Latency неограничена

Latency

(в секундах)

Нужно предсказать время одного forward pass
Latency зависит от конкретной GPU

$$\Theta = (t_0, t_{\text{launch}}, BW, R, P)$$

Для каждого слоя: $T_{L, \ell} = t_{\text{launch}}$ задержка запуска GPU

Если слой ℓ требует $F_{\ell}(S, B)$ операций,
а вычислительная производительность GPU

равна $R_{\ell} \leftarrow \text{FLOPs} / s$, тогда вычислительное
время $T_{\text{compute}, \ell} = \frac{F'_{\ell}(S, B)}{R_{\ell}} = \frac{B F_{\ell}(S)}{R_{\ell}}$

т.к. FLOPs для одного изображения
составляет $F_{\ell}(S)$, а для батча B — $B \cdot F_{\ell}(S)$

Для каждого слоя мы найдем

$$M_{\ell}(S, B) = \text{Bytes Moved}_{\ell}(S, B)$$

bytes

Если пропускная способность памяти BW ,
то время передачи данных $T_{\text{memory}, \ell} = \frac{M_{\ell}(S, B)}{BW}$

Итого, для слоя l :

$$T_l = \max \left(t_{\text{launch}}, \frac{BF_l(S)}{R_l}, \frac{M_l(S, B)}{BW} \right)$$

Для объединения трех ограничений
используем L_p приближение максимума

$$T_l(S, B) = \left[t_{\text{launch}}^p + \left(\frac{BF_l(S)}{R_l} \right)^p + \left(\frac{M_l(S, B)}{BW} \right)^p \right]^{\frac{1}{p}}$$

$$p=1 \Rightarrow T_l = T_{\text{launch}} + T_{\text{compute}} + T_{\text{memory}}$$

$$p \rightarrow \infty \Rightarrow T_l = \max(\dots)$$

t_0 - постоянные зап. расходы всего
forward pass

тогда $\text{Latency}(S, B, \theta) = t_0 + \sum_l T_l$

$$\text{Latency}(S, B, \theta) = t_0 + \sum_l \left[t_{\text{launch}}^p + \left(\frac{BF_l(S)}{R_l} \right)^p + \left(\frac{M_l(S, B)}{BW} \right)^p \right]^{\frac{1}{p}}$$

$t_{\text{launch}} \max \Rightarrow$ launch bound
аналогично compute bound

$\frac{M_l}{BW} \max \Rightarrow$ memory-bound

Поиск камбоджи на T4 Google Colab:

$$t_0 = 4.9 \cdot 10^{-5} \text{ s}$$

$$t_{\text{launch}} = 2.76 \cdot 10^{-5} \text{ s}$$

$$\text{BW} = 5.57 \cdot 10^{10} \text{ B/s}$$

$$R \approx 1.13 \cdot 10^{13} \text{ FLOP/s}$$

$$p = 49.77$$

Energy efficiency comparison

Energy

$$\text{Energy}(S, B, \theta_e)$$

$$E = E_{\text{static}} + E_{\text{compute}} + E_{\text{memory}}$$

GPU потребляет некоторую базовую мощность $P_{\text{static}} \leftarrow W$

$$E_{\text{static}} = P_{\text{static}} \cdot \text{Latency}(S, B, \theta)$$

Если e_{flop} — энергия одной floating-point операции, то $E_{\text{compute}} = e_{\text{flop}} \cdot \text{FLOPs}(S, B)$

$$E_{\text{memory}} = e_{\text{byte}} \cdot \text{Bytes Moved}(S, B)$$

e_{byte} — энергия на 1 переданный байт

Учто

$$\text{Energy}(S, B, \theta_e) = P_{\text{static}} \cdot \text{Latency}(S, B, \theta) + e_{\text{flop}} \cdot \text{FLOPs}(S, B) + e_{\text{byte}} \cdot \text{Bytes Moved}(S, B)$$

$$\theta_e = (P_{\text{static}}, e_{\text{flop}}, e_{\text{byte}}, \theta)$$

параметры
возбуждения
но измеренные
GPU

Если подставить найденное

$$\text{Energy}(S, B, \theta_c) = P_{\text{static}} \cdot \text{Latency}(S, B, \theta_c) + \\ + e_{\text{flop}} \cdot B (17751S^2 + 314468) + \\ + 4e_{\text{byte}} \cdot [1040324 + 91BS^2 + 2148B]$$

После канонизации на T4:

$$P_{\text{static}} \approx 55.8W$$

$$e_{\text{flop}} = 0$$

$$e_{\text{byte}} = 1.12 \cdot 10^{-10} \text{ J/B}$$